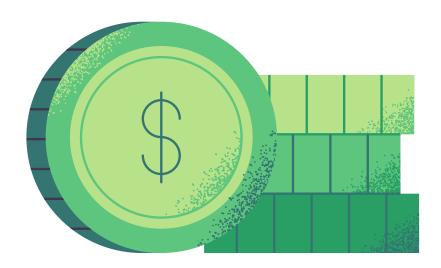




# Riesgos

¿Cómo saber si nos enfrentamos a un riesgo de morosidad o impago por edad?

En este proyecto estamos tratando de predecir si el cliente es apto para un crédito, analizando su edad, historial, tipo de petición...







### Datos Utilizados

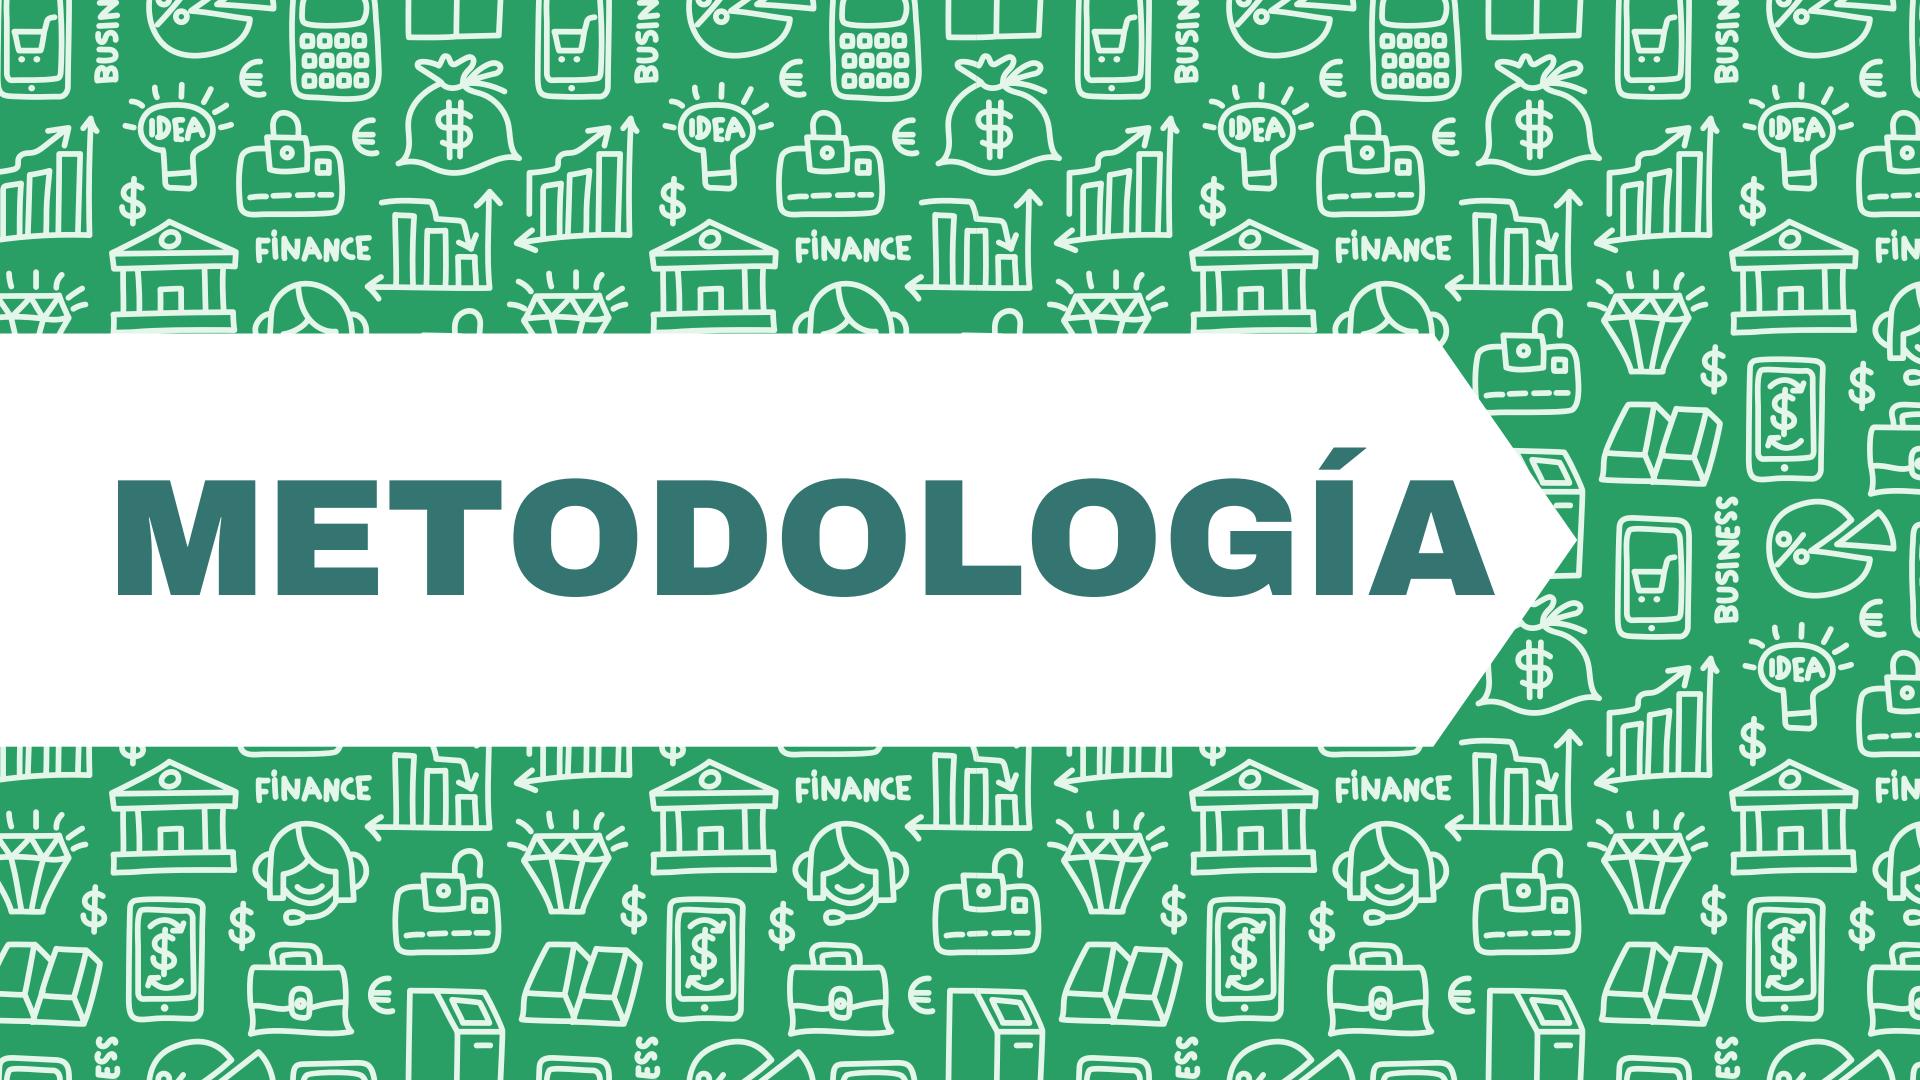
#### Usaremos el Credit Risk Dataset de Kaggle:

Datos Simulados de Kaggle

3

Variables – Edad, Propiedades, Tipo de Crédito, Cantidad...

Registros - 32581 entradas con nulos y valores anomalos.



# Prepocesamiento



- 0.8

- 0.6

- 0.4

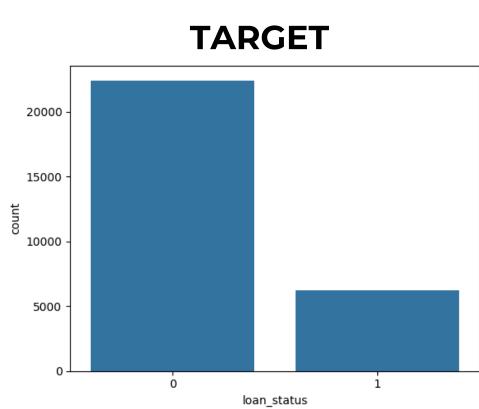
- 0.2

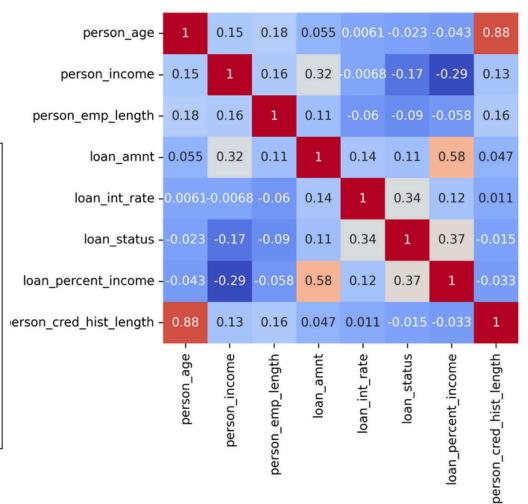
0.0

Manejo de nulos y selección de caracteristicas.

Dada la gran cantidad de **nulos** (casi 5000) se eliminaron las entradas con nulos. Durante el proceso de los datos, también tratamos los valores **anómalos** en edad y en antigüedad laboral.

Así mismo se reviso la **correlación** y la selección del **target**.





#### Prueba de Modelos

Se probarón distintos modelos de ML, buscando el que de una mejor Accuracy y pueda trabajar con el desbalanceo del target.

Logistic Regresion
Tree Decisión
Random Forest
Support Vector Machine (SVC)
Naive Bayes
Gradient Boosting Classifier
XGBooster Classifier
CatBooster Classifier



# Validación y Evaluación

#### **Métricas:**

Divisón del Dataset:

Accuracy (Nuestra principal métrica)

80% Train

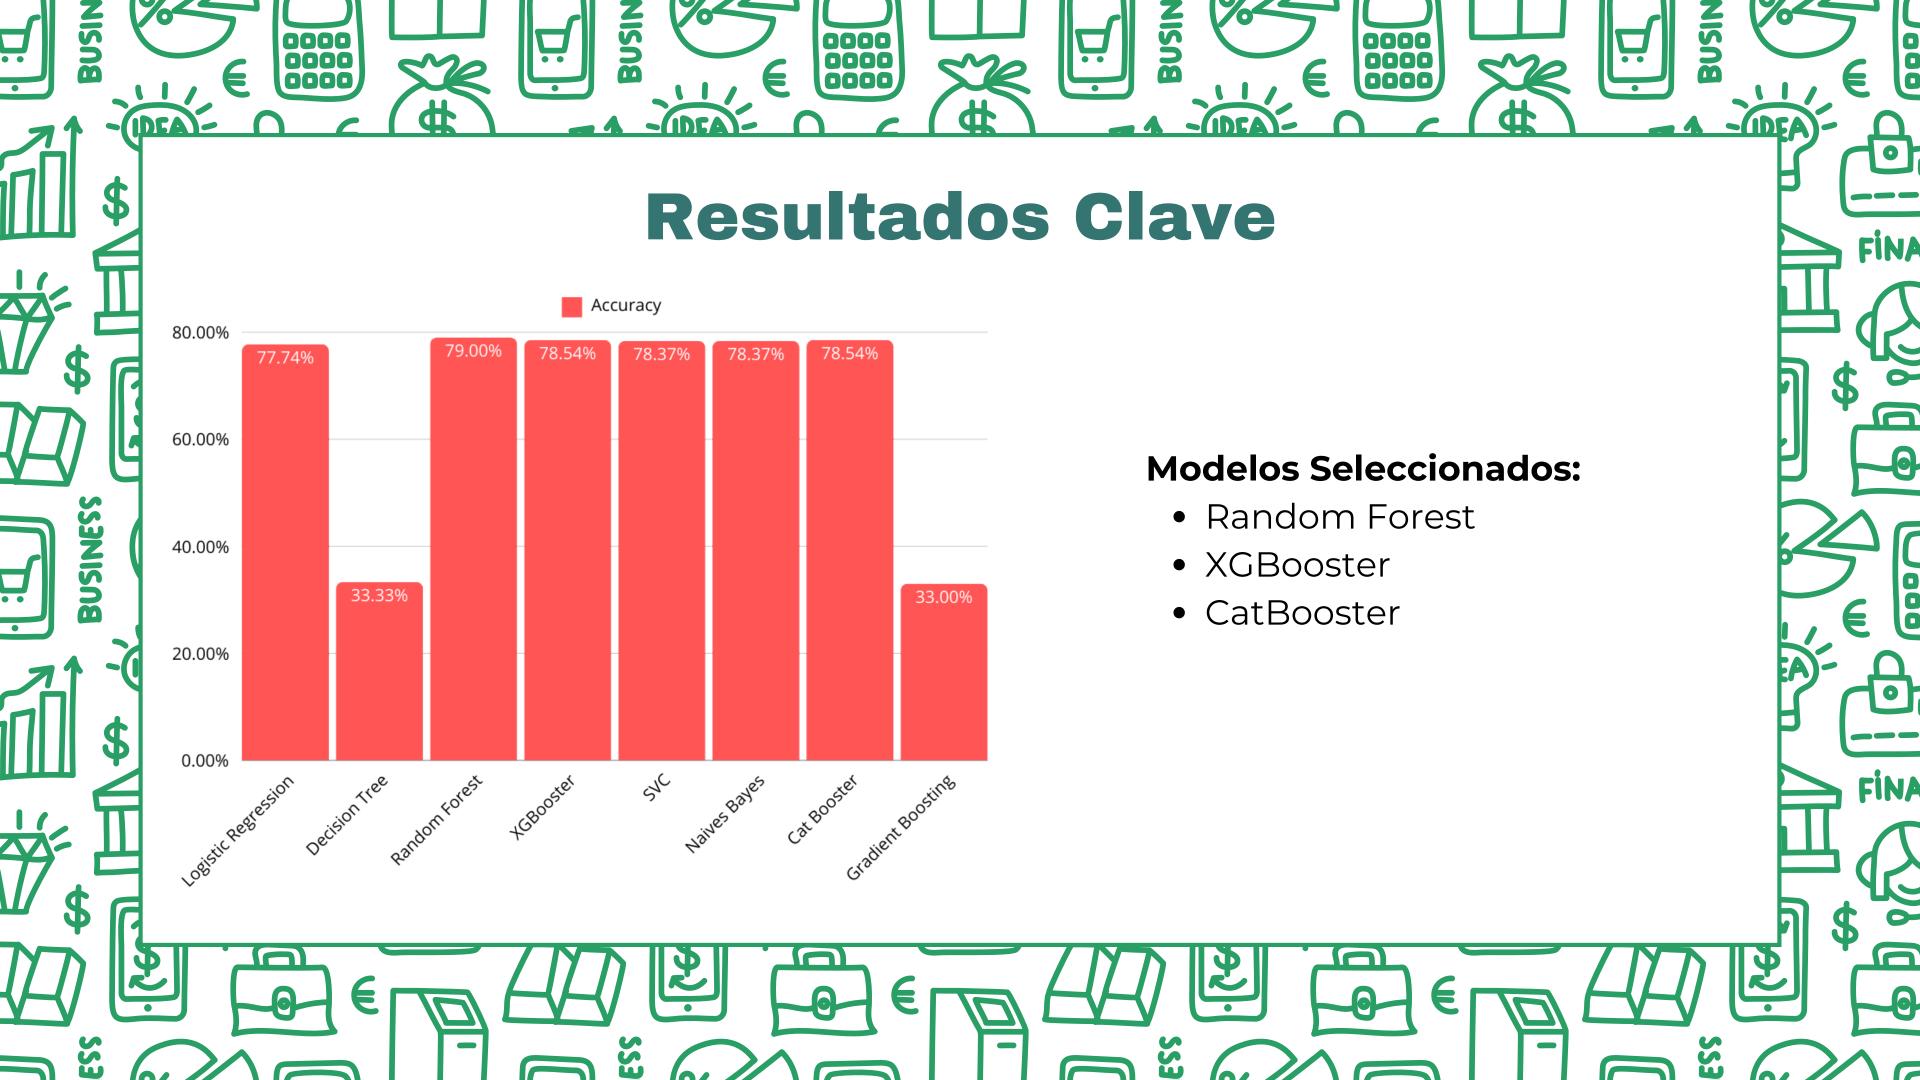
- Precisión
- F1 Score
- Recall

Se escalaron las features necesarias.



20% Test



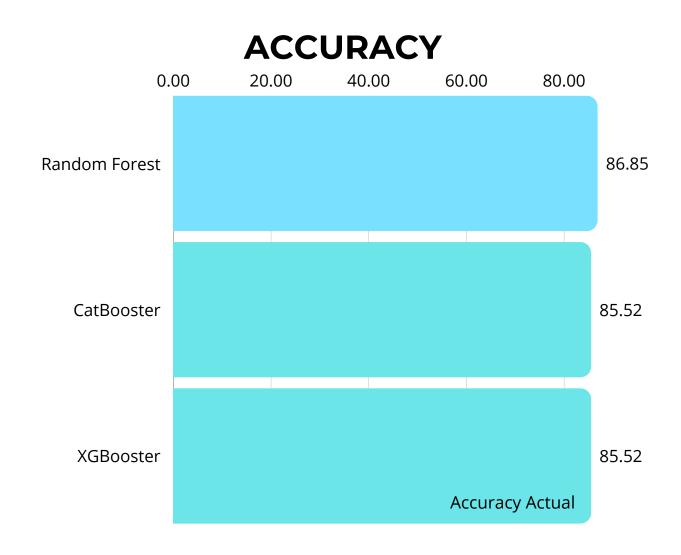


# Optimización



# Usamos un GridSearch para la optimización y...

Usando un paramsgrid conseguimós estos resultados:





#### Random Forest

Dada la mejora y sus resultados, el Random Forest presenta un alto porcentaje de predicción y fiabilidad.

Por lo tanto, sera nuestro modelo.

86.85%



# Aplicaciones Reales

#### ¿Cómo afectaria usar este modelo?

Menor riesgo de morosidad.

3

Rápidez a la hora de tomar decisiones.

Mejora en el proceso selección.

### Gracias por su atención

- victordesousasanchez@gmail.com
- <u>Linkedin</u>